Monitoramento Inteligente de Sistemas Espaciais com Redes Neurais

Global Solution 2026.1 — DL-CNN — FIAP

Plataforma Orbital Climate Intelligence

---

1. Estratégia Adotada

O problema consiste em classificar o estado operacional de sistemas espaciais simulados em três categorias — **Operação Normal (0)**, **Alerta Operacional (1)** e **Falha Crítica Iminente (2)** — a partir de 25 features de sensores e telemetria derivadas do dataset C-MAPSS da NASA (16.504 amostras de treino, 4.127 de teste, sem valores nulos).

A estratégia foi construir uma progressão de 7 modelos partindo do **Perceptron Puro** (baseline linear, sem camadas ocultas) até MLPs com diferentes configurações, isolando o efeito de cada decisão arquitetural sobre os resultados.

Normalização: StandardScaler (Z-score)

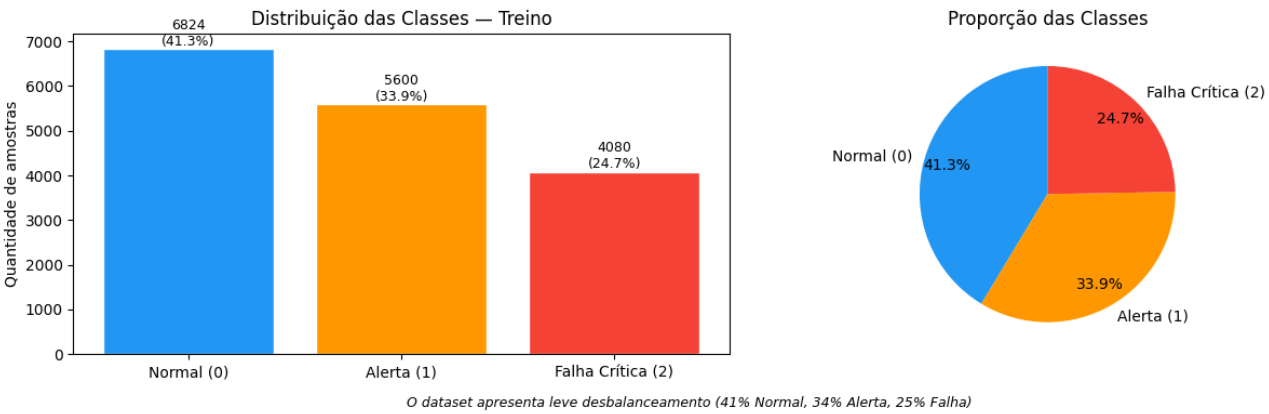
As features possuem escalas extremamente heterogêneas: `op_setting_2` oscila em torno de 0,0004 enquanto `sensor_1` é fixo em 518,67. Sem normalização, o gradiente durante o backpropagation seria dominado pelas features de maior magnitude. O **StandardScaler** transforma cada feature para média zero e desvio padrão unitário. O scaler foi ajustado exclusivamente nos dados de treino e aplicado ao teste, evitando *data leakage*.

```
Após StandardScaler (treino):
 Média global:          ≈ 0.000000
 Desvio padrão global:  ≈ 0.720000
```

---

2. Análise Exploratória dos Dados

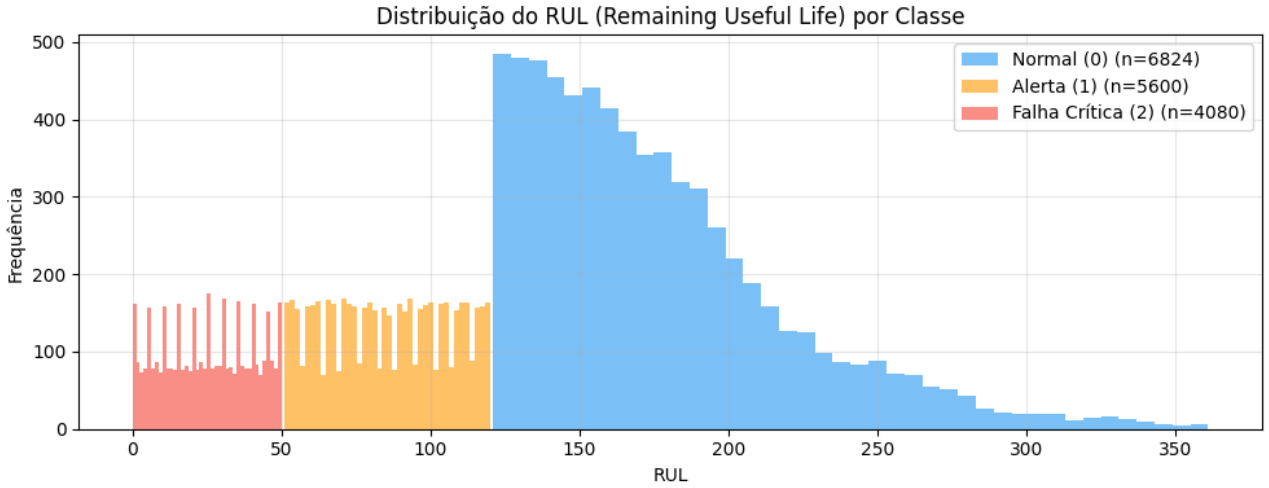
2.1 Distribuição das Classes



O dataset apresenta leve desbalanceamento (41% Normal, 34% Alerta, 25% Falha)

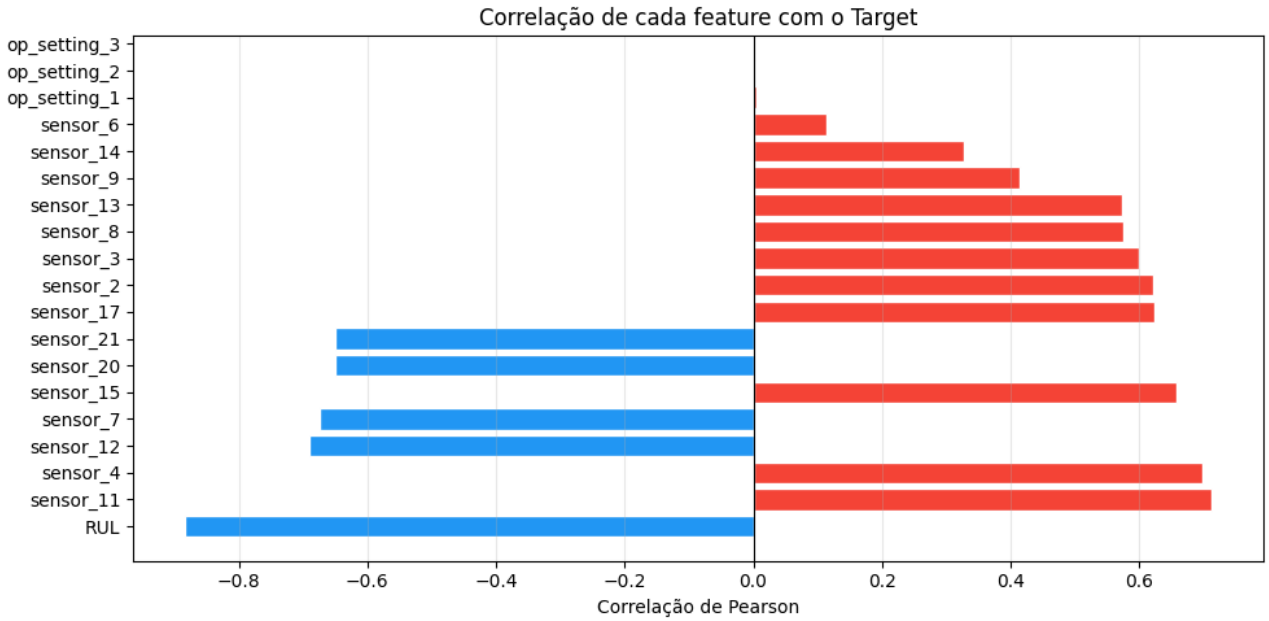
O dataset apresenta leve desbalanceamento: **Normal (0)** com 6.824 amostras (41.3%), **Alerta (1)** com 5.600 (33.9%) e **Falha Crítica (2)** com 4.080 (24.7%). A classe minoritária é justamente a mais crítica operacionalmente.

2.2 Distribuição do RUL por Classe



O gráfico revela o fator decisivo do dataset: o **RUL (Remaining Useful Life)** separa as três classes de forma quase perfeita. Falha Crítica concentra-se em RUL 0–50, Alerta em 50–125 e Operação Normal em 125–361. Esse padrão explica por que mesmo um classificador linear consegue alta accuracy após normalização.

2.3 Correlação das Features com o Target



O **RUL** tem a maior correlação com o target (≈ –0.90, forte e negativa). Entre os sensores, **sensor_11**, **sensor_4** e **sensor_15** se destacam com correlações acima de 0.65. As features `op_setting_1`, `op_setting_2` e `op_setting_3` têm correlação próxima de zero — pouco informativas para a classificação. Esse perfil confirma a alta separabilidade linear do dataset após normalização.

---

3. Modelos Testados

Foram treinados 7 modelos com 100 épocas, `categorical_crossentropy` como função de perda e `softmax` na camada de saída:

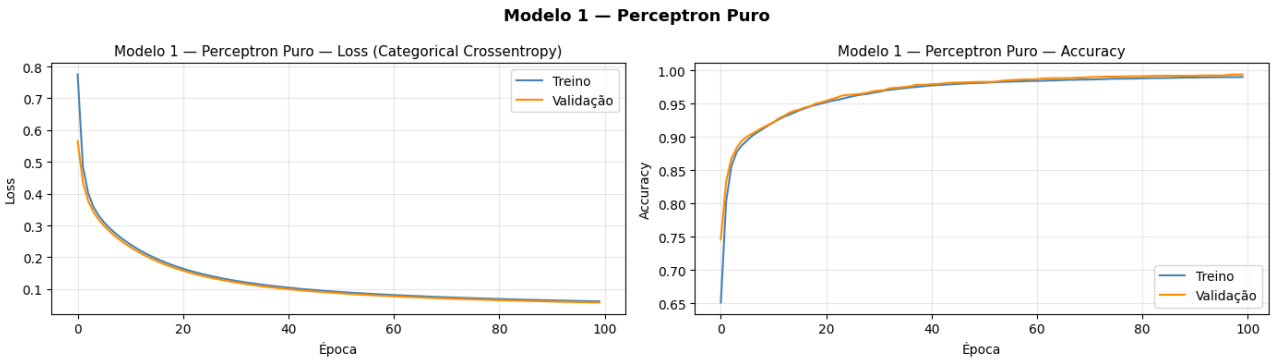
#	Modelo	Arquitetura	Ativação	Otimizador	Batch	Parâmetros
1	Perceptron Puro	Input → Dense(3)	softmax	Adam	32	78
2	MLP 1 Camada (32)	Input → Dense(32) → Dense(3)	ReLU	Adam	32	931

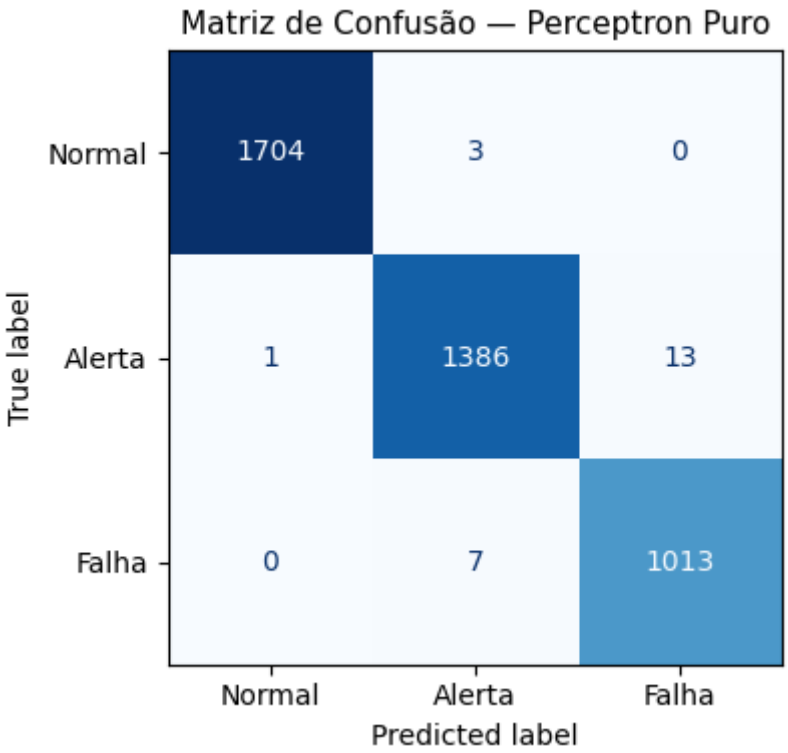
3	MLP 1 Camada (128)	Input → Dense(128) → Dense(3)	ReLU	Adam	32	3.715
4	MLP 2 Camadas (128→64)	Input → Dense(128) → Dense(64) → Dense(3)	ReLU	Adam	32	11.779
5	MLP com Dropout	Dense(128) → Drop(0.3) → Dense(64) → Drop(0.3) → Dense(3)	ReLU	Adam	32	11.779
6	MLP tanh + SGD	Input → Dense(128) → Dense(64) → Dense(3)	tanh	SGD (lr=0.01, mom=0.9)	32	11.779
7	MLP batch=128	Input → Dense(128) → Dense(64) → Dense(3)	ReLU	Adam	128	11.779

---

4. Resultados por Modelo

Modelo 1 — Perceptron Puro



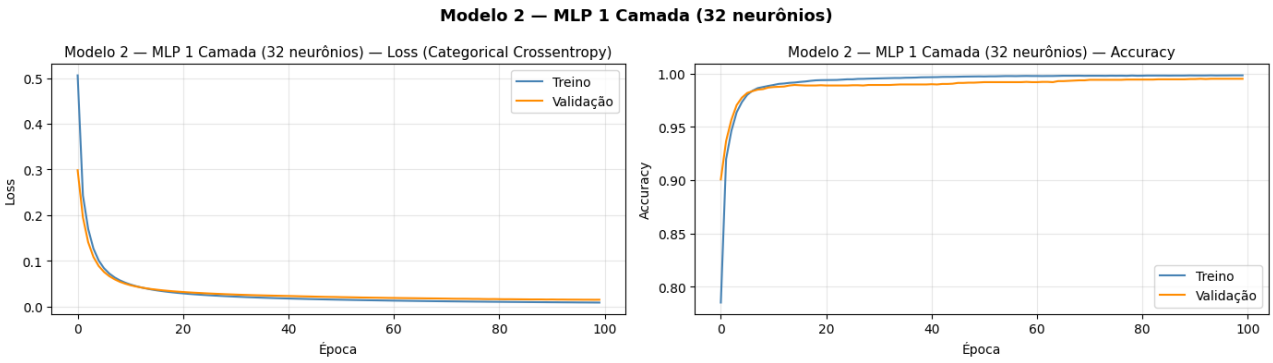


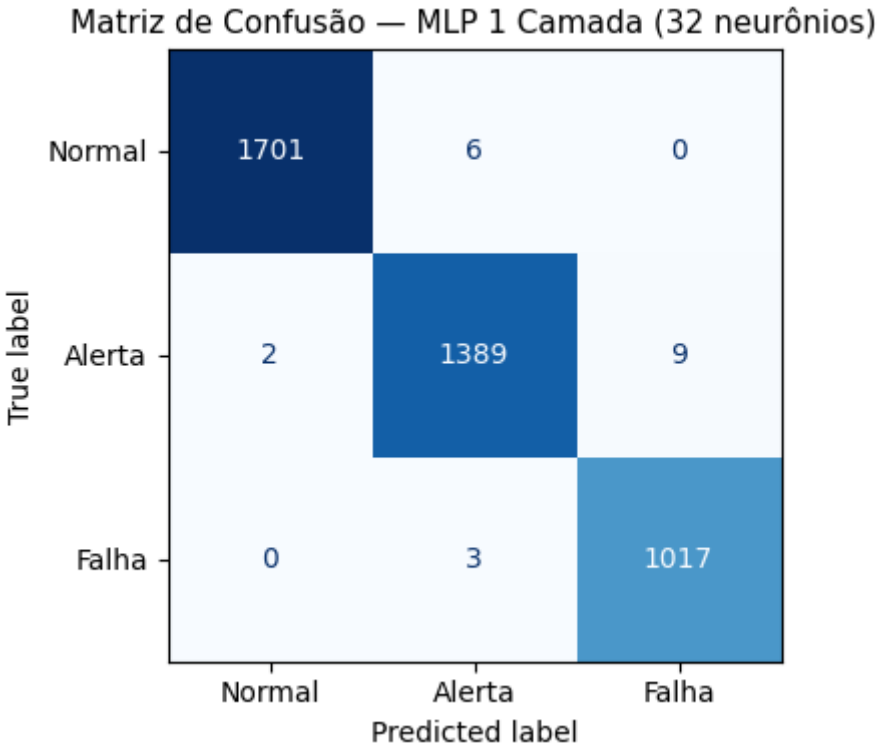
Accuracy: 99.42% | Val Loss: 0.0576 | Train Loss: 0.0611 | Gap: –0.0035

As curvas de loss e accuracy convergem de forma suave e progressiva ao longo das 100 épocas, com as linhas de treino e validação praticamente sobrepostas. Destaque importante: o **train*loss (0.0611) ficou acima do val*loss (0.0576)**, gap negativo de –0.0035 — padrão de underfitting leve, confirmado visualmente pelas curvas. O modelo não conseguiu ajustar completamente nem os dados de treino devido à fronteira linear.

Na matriz de confusão: 1.704 Normal corretos (3 → Alerta, 0 → Falha), 1.386 Alerta corretos (1 → Normal, 13 → Falha), 1.013 Falha corretos (0 → Normal, 7 → Alerta). Os 13 erros de Alerta classificados como Falha são aceitáveis operacionalmente; mais críticos seriam erros na direção oposta.

Modelo 2 — MLP 1 Camada (32 neurônios, ReLU)

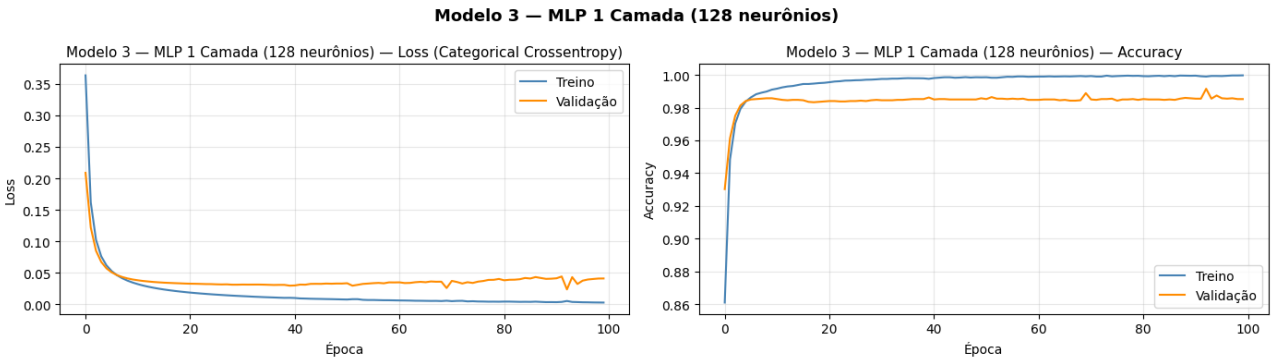


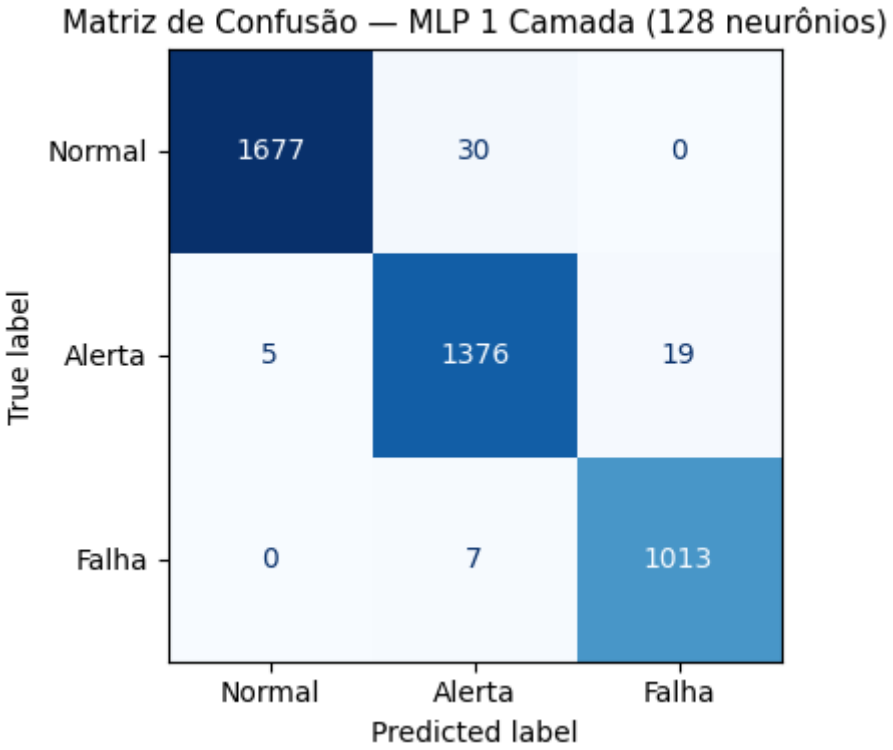


Accuracy: 99.52% | Val Loss: 0.0146 | Train Loss: 0.0084 | Gap: +0.0062

Melhor modelo do experimento. A convergência é muito mais rápida que o Perceptron — as curvas estabilizam em torno da época 20 e permanecem estáveis até o fim. O val_loss (0.0146) é o menor de todos os 7 modelos, e o gap treino/validação (0.0062) é o menor entre os MLPs, indicando excelente generalização com apenas 931 parâmetros.

Modelo 3 — MLP 1 Camada (128 neurônios, ReLU)

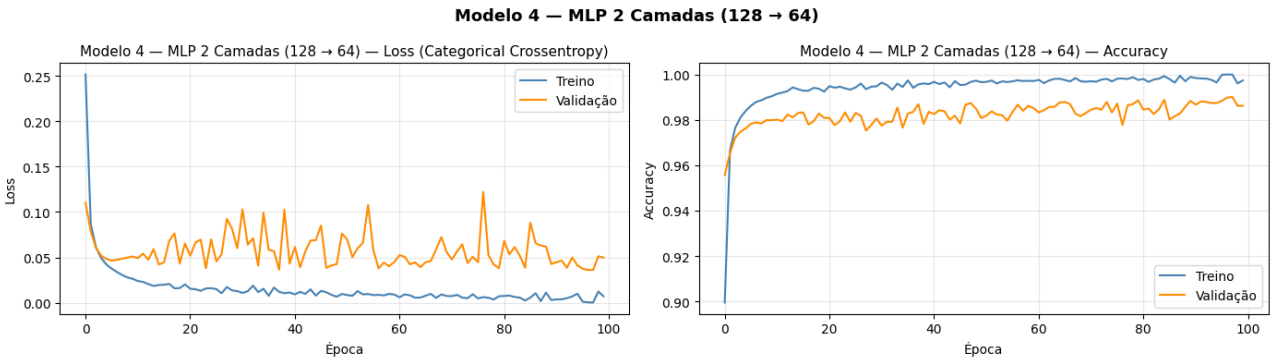


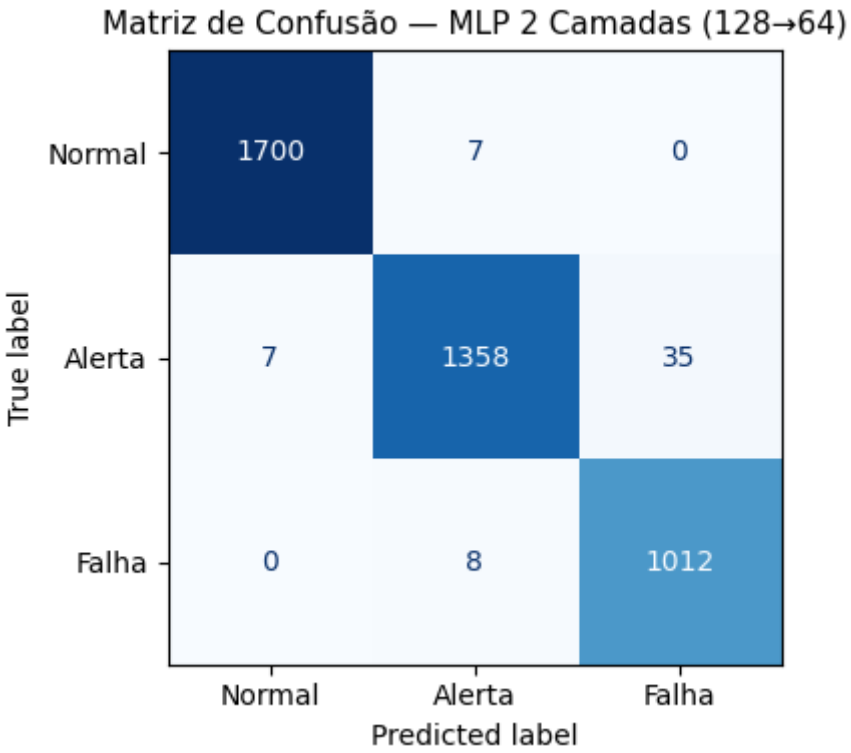


Accuracy: 98.52% | Val Loss: 0.0412 | Train Loss: 0.0029 | Gap: +0.0382

Pior modelo do experimento. Aumentar os neurônios de 32 para 128 piorou tanto a accuracy quanto o val*loss. O train*loss chegou a 0.0029 — o mais baixo entre os modelos de 1 camada — mas o val_loss subiu para 0.0412, resultando no maior gap dos modelos de 1 camada (0.0382). A rede com mais capacidade memorizou padrões específicos do treino que não generalizam.

Modelo 4 — MLP 2 Camadas (128→64, ReLU)

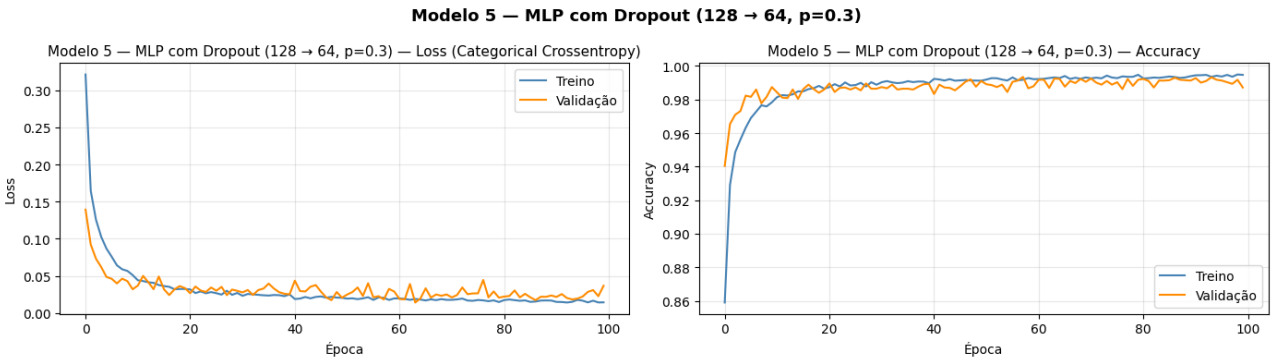


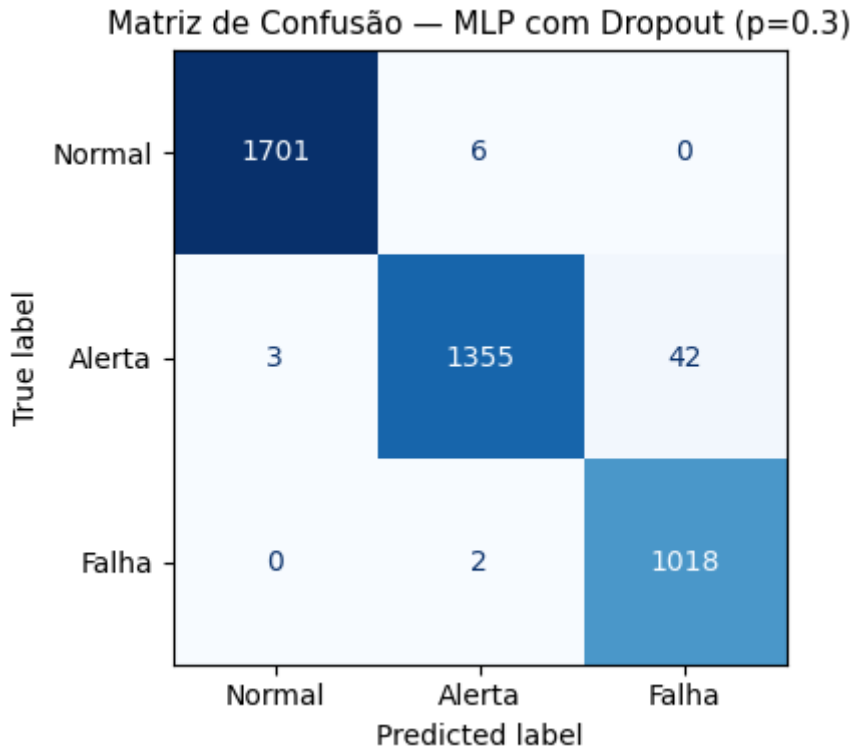


Accuracy: 98.62% | Val Loss: 0.0498 | Train Loss: 0.0071 | Gap: +0.0427

A segunda camada oculta não trouxe melhora — o val_loss (0.0498) foi o **maior de todos os 7 modelos**. O gap de 0.0427 é o mais alto do experimento, sinalizando a maior tendência ao superajuste, embora sem cruzar o limiar de 0.05. Para este dataset, a profundidade adicional agravou a memorização de padrões específicos do treino.

Modelo 5 — MLP com Dropout (128→64, p=0.3)





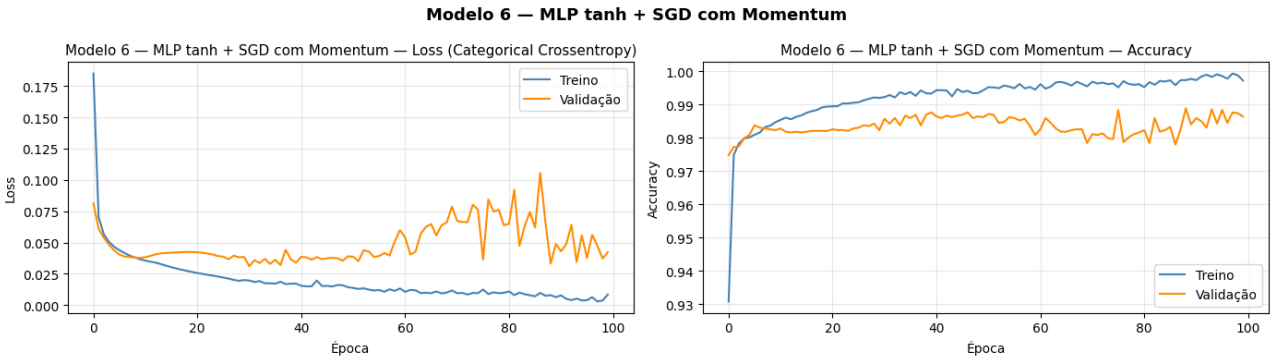
Accuracy: 98.72% | Val Loss: 0.0367 | Train Loss: 0.0144 | Gap: +0.0223

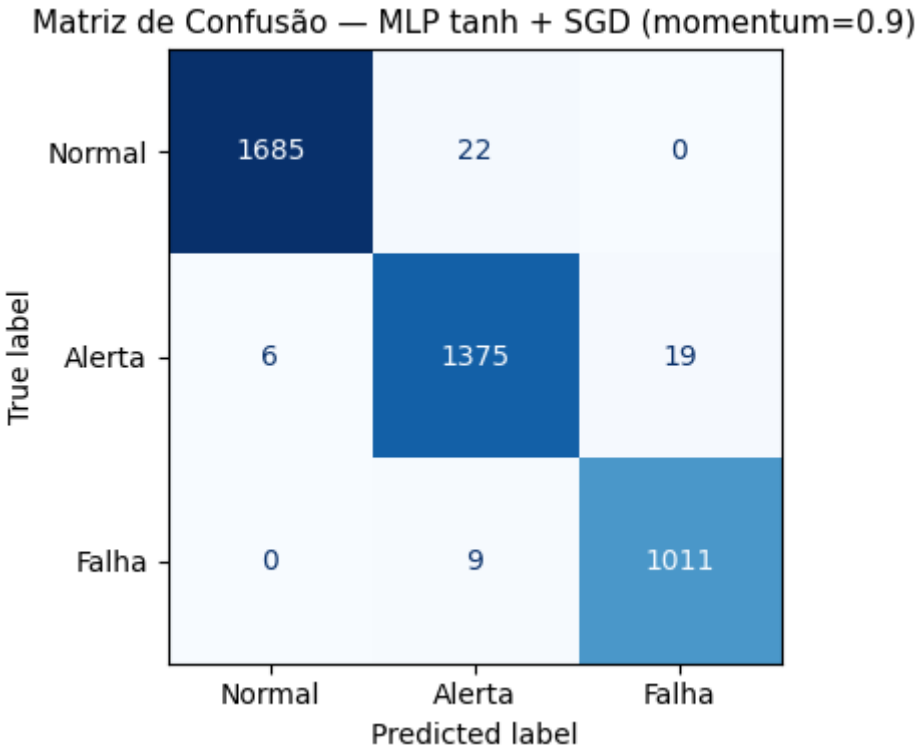
As curvas mostram o comportamento característico do Dropout: **oscilação contínua na val*loss* e *val*accuracy** ao longo das 100 épocas, reflexo do ruído introduzido ao desativar aleatoriamente 30% dos neurônios a cada batch. Comparado ao Modelo 4 (mesma arquitetura sem Dropout), o val_loss caiu de 0.0498 para 0.0367 e o gap reduziu de 0.0427 para 0.0223, confirmando a eficácia da regularização.

O train*loss (0.0144) ficou **abaixo** do val*loss (0.0367) — padrão normal, onde val > train. O Dropout aumentou o train_loss em relação ao Modelo 4 (de 0.0071 para 0.0144) porque o ruído dificulta o ajuste ao treino, mas isso não inverteu a relação com a validação.

Recall para Falha Crítica: 0.9980 — o mais alto de todos os 7 modelos. Modelo mais seguro para uso em produção.

Modelo 6 — MLP tanh + SGD com Momentum

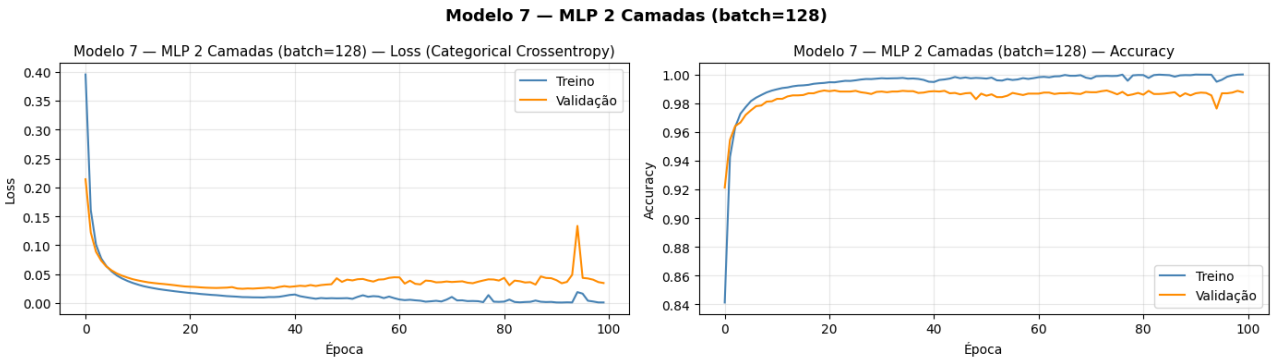


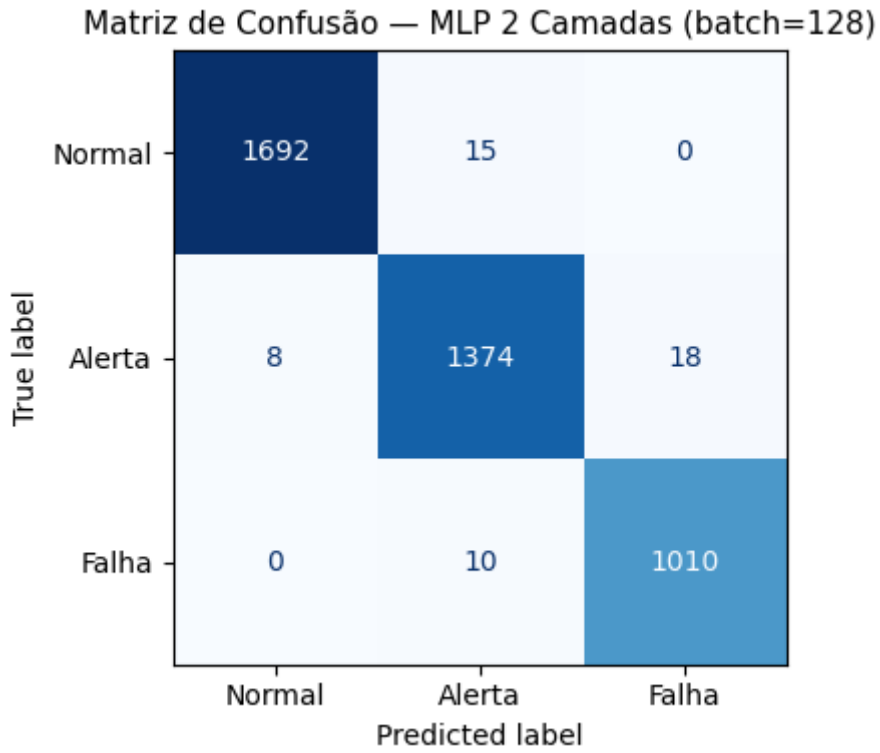


Accuracy: 98.64% | Val Loss: 0.0422 | Train Loss: 0.0084 | Gap: +0.0338

Accuracy competitiva, mas o perfil de recall é o pior do experimento: **Recall Falha = 0.9912** e **Recall Normal = 0.9871** — os valores mais baixos em ambas as classes extremas. O SGD com momentum, sem taxa de aprendizado adaptativa por parâmetro, convergiu para uma solução com maior viés de classificação, penalizando as classes extremas. A ativação tanh não trouxe vantagem sobre o ReLU neste contexto.

Modelo 7 — MLP batch=128





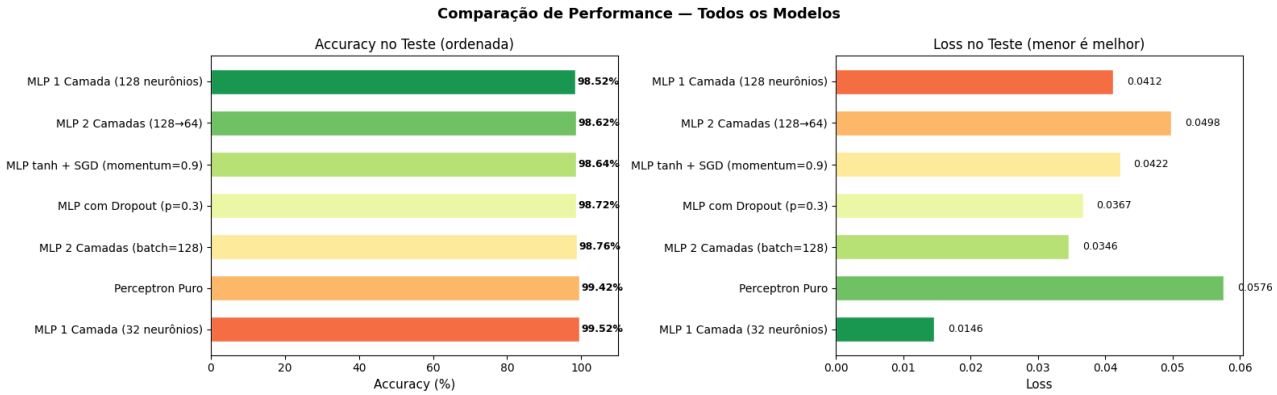
Accuracy: 98.76% | Val Loss: 0.0346 | Train Loss: 0.0011 | Gap: +0.0335

O **menor train_loss do experimento (0.0011)** confirma que gradientes calculados sobre mais amostras por iteração ajustam o treino com maior precisão. Porém, o val*loss (0.0346) e o* ***recall para Falha Crítica (0.9902)*** *— o mais baixo entre os modelos com Adam — mostram que essa precisão no treino não se traduziu em melhor generalização. A comparação direta com o Modelo 4 (mesma arquitetura, batch=32) evidencia o trade-off: batch=32 teve train*loss maior (0.0071) mas recall para Falha superior (0.9922 vs 0.9902).

---

5. Comparação Geral

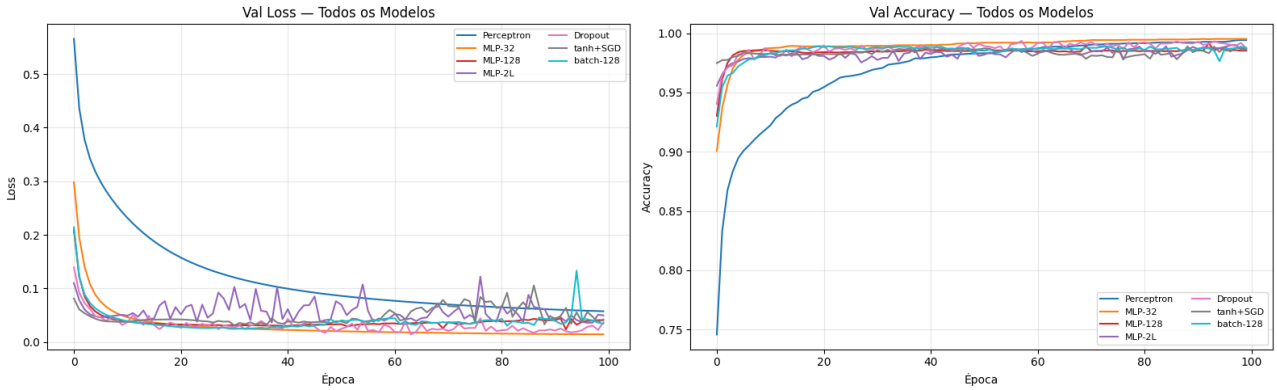
5.1 Ranking por Accuracy e Loss



Posição	Modelo	Accuracy (%)	Val Loss	Train Loss	Gap
■ 1º	MLP 1 Camada (32 neurônios)	**99.52**	0.0146	0.0084	+0.0062
■ 2º	Perceptron Puro	99.42	0.0576	0.0611	–0.0035
3º	MLP 2 Camadas (batch=128)	98.76	0.0346	0.0011	+0.0335
4º	MLP com Dropout	98.72	0.0367	0.0144	+0.0223
5º	MLP tanh + SGD	98.64	0.0422	0.0084	+0.0338
6º	MLP 2 Camadas (128→64)	98.62	0.0498	0.0071	+0.0427
7º	MLP 1 Camada (128 neurônios)	98.52	0.0412	0.0029	+0.0382

> Nenhum modelo ultrapassou o gap de 0.05 — nenhum apresentou overfitting severo.

5.2 Curvas de Validação Sobrepostas



O gráfico sobrepostos revela padrões importantes: - **Perceptron (azul):** curva de val*loss significativamente mais alta e lenta para convergir — visível a diferença de escala em relação aos MLPs* - ***MLP-32 (laranja):*** *converge mais rápido que todos e mantém o val*loss mais baixo e estável - **MLP-2L (roxo) e tanh+SGD (cinza):** maior oscilação nas curvas de validação ao longo das épocas - **batch-128 (ciano):** oscilação crescente na val_loss nas épocas finais, reflexo de gradientes excessivamente precisos que ajustam padrões específicos do treino

5.3 Recall por Classe — Métrica Crítica para Sistemas Espaciais

Modelo	Accuracy (%)	Recall Falha Crítica	Recall Normal
Perceptron Puro	99.42	0.9931	0.9982
MLP 32	99.52	0.9971	0.9965
MLP 128	98.52	0.9931	0.9824
MLP 2 Camadas	98.62	0.9922	0.9959
MLP Dropout	**98.72**	**0.9980**	**0.9965**
tanh + SGD	98.64	0.9912	0.9871
batch=128	98.76	0.9902	0.9912

---

6. Análise Crítica

6.1 Simplicidade venceu a complexidade

O resultado mais relevante foi o **ranking inverso ao número de parâmetros**: o melhor modelo por accuracy (MLP-32, 931 parâmetros) superou todos os modelos com 11.779 parâmetros. O pior modelo foi o MLP-128 (3.715 parâmetros), que se saiu pior que o Perceptron Puro com apenas 78 parâmetros.

Isso se explica pela combinação de dois fatores visíveis no EDA: o RUL separa as classes de forma quase perfeita (fig*09*01) e tem correlação próxima de –0.90 com o target (fig*10*02). Num dataset com padrão tão estruturado após normalização, modelos com excesso de capacidade memorizam ruído específico do treino em vez de generalizar.

6.2 Perceptron Puro em 2º lugar — underfitting confirmado pelas curvas

As curvas do Modelo 1 (fig*19*04) confirmam visualmente o underfitting: as linhas de treino e validação são quase idênticas e convergem lentamente ao longo de todas as 100 épocas, sem a queda rápida característica dos MLPs. O train*loss final (0.0611) ficou acima do val*loss (0.0576) — gap negativo de –0.0035 — o único modelo com esse comportamento invertido, inequívoco de underfitting.

6.3 Dropout — comportamento visual característico confirmado

As curvas do Modelo 5 (fig*35*12) mostram o comportamento típico de Dropout: **oscilação contínua nas curvas de val*loss e val*accuracy** mesmo nas épocas finais. Isso ocorre porque a cada batch de treino uma sub-rede diferente é ativada, criando predições instáveis durante a avaliação. Apesar da aparência "barulhenta", o resultado final foi o melhor recall para Falha Crítica (0.9980) — a regularização funcionou.

6.4 O erro mais crítico do SGD — viés de classificação

O Modelo 6 (tanh+SGD) obteve 98.64% de accuracy, mas seus 13 erros nas classes extremas foram proporcionalmente piores: recall Falha=0.9912 e recall Normal=0.9871, os mais baixos do experimento. O SGD sem taxa adaptativa convergiu para um mínimo local que privilegia a classe majoritária (Alerta, 33.9%) em detrimento das classes extremas.

6.5 batch=128 — ajuste preciso do treino, generalização comprometida

O train*loss de 0.0011 no Modelo 7 é 6x menor que o do Modelo 4 (mesma arquitetura, batch=32: train=0.0071), porém o val*loss (0.0346) e o recall para Falha (0.9902) foram piores. Visualmente (fig*43*16), as curvas de val_loss mostram oscilação crescente nas épocas finais — sinal de que o modelo bem ajustado ao treino não encontrou um mínimo robusto para generalização.

7. Conclusões

Os dados confirmaram conclusões que vão contra a intuição inicial:

Normalização foi decisiva: O StandardScaler tornou o problema quasi-linearmente separável — até o Perceptron Puro alcançou 99.42%.

Melhor modelo: MLP-32 (99.52%) — apenas 931 parâmetros, convergência rápida em ~20 épocas, menor val_loss (0.0146) e menor gap treino/validação (+0.0062) entre os MLPs.

Pior modelo: MLP-128 (98.52%) — mais neurônios aumentaram o train_loss baixo (0.0029) mas dispararam o gap (0.0382), memorizando ruído do treino.

Profundidade não ajudou: MLP 2 camadas teve o maior val_loss (0.0498) e o maior gap (+0.0427) de todos os modelos, ficando em 6º lugar.

Dropout é o modelo para produção: apesar de 4º em accuracy (98.72%), obteve o maior recall para Falha Crítica (0.9980). Em sistemas espaciais, não detectar uma falha iminente é mais custoso que qualquer redução de accuracy.

SGD gerou o pior perfil de recall: piores valores para Falha (0.9912) e Normal (0.9871), inadequado para monitoramento crítico.

batch=128 prejudicou a sensibilidade: menor train_loss (0.0011), mas pior recall para Falha entre os modelos Adam (0.9902).

Accuracy isolada não é suficiente: a variação total de accuracy foi de apenas 1 ponto percentual (98.52% a 99.52%), enquanto o recall para Falha variou de 0.9902 a 0.9980 — diferença operacionalmente significativa.
